

Laporan Praktikum 1: Scraping & Eksplorasi Data (EDA)

Nama: Maulana Rhys Pradana

NRP: 5054251041

Sumber Data: <https://sofifa.com/>

1. Deskripsi dataset

Diperoleh melalui proses *web scraping* dari situs web SoFIFA, sebuah basis data daring yang mencatat atribut pemain sepak bola (FC 26). Hasil ekstraksi data menghasilkan struktur tabular yang terdiri dari 1554 baris observasi (pemain) dan 5 kolom fitur/atribut.

Karakteristik :

- Nama: Tipe data Nominal (Kategorikal). Merupakan nama panggilan atau nama lengkap pemain.
- Posisi: Tipe data Nominal (Kategorikal). Menunjukkan peran utama pemain di lapangan (misal: CB, ST, CM).
- Umur: Tipe data Numerik (Diskrit). Merepresentasikan usia pemain dalam satuan tahun.
- Overall Rating: Tipe data Numerik (Diskrit). Nilai kemampuan keseluruhan pemain saat ini pada skala 1-100.
- Potential: Tipe data Numerik (Diskrit). Proyeksi nilai kemampuan maksimal yang dapat dicapai pemain di masa depan pada skala 1-100.

2. Statistik Deskriptif

- Atribut Numerik : Mayoritas pemain dalam dataset berada pada rentang usia produktif, dengan rata-rata umur di kisaran 24-26 tahun. Nilai Overall Rating memiliki rata-rata di angka 60-an, yang merupakan standar umum pemain sepak bola profesional kelas menengah. Sementara itu, atribut *Potential* memiliki nilai rata-rata yang sedikit lebih tinggi dari Overall Rating, mengindikasikan banyak pemain muda yang masih bisa berkembang.
- Atribut Kategorikal :
Dari perhitungan frekuensi posisi pemain, posisi pemain bertahan seperti CB (*Center Back*) dan posisi penyerang ST (*Striker*) merupakan jenis posisi dengan ketersediaan jumlah (stok) terbanyak dalam basis data ini.


3. Penanganan Data

- Missing Value :
Pengecekan dilakukan menggunakan fungsi "isnull().sum()". Terdapat beberapa baris yang gagal memuat informasi akibat format tag HTML yang tidak seragam saat scraping. Penanganan dilakukan dengan metode penghapusan baris (listwise deletion) menggunakan perintah "dropna()" agar tidak mengganggu kalkulasi statistik.


- Outlier :

Deteksi outlier dilakukan menggunakan grafik Boxplot. Ditemukan adanya pencilan ekstrem pada atribut Umur (terdapat data pemain yang usianya sangat tua/tidak wajar untuk ukuran atlet aktif). Langkah yang diambil adalah melakukan pemfilteran (subsetting), yaitu hanya mempertahankan baris data pemain yang memiliki usia kurang dari atau sama dengan 45 tahun.

4. Visualisasi & Interpretasi



Berdasarkan histogram, distribusi Overall Rating pemain mendekati distribusi normal (kurva lonceng) yang berpusat di rentang skor 60-70. Sangat sedikit pemain yang memiliki rating sangat buruk atau sangat elit (>85). Melalui diagram batang, dapat divalidasi bahwa posisi CB (Center Back) merupakan peran yang paling mendominasi dataset, disusul oleh posisi penyerang sentral (ST).



Pada *scatter plot*, terlihat pola tren melengkung antara Umur dan *Overall Rating*. Rating pemain cenderung terus naik seiring bertambahnya usia, mencapai puncaknya di usia emas (sekitar 28-32 tahun), kemudian perlahan stagnan atau menurun. Hal ini didukung oleh *Correlation Heatmap*, di mana *Overall Rating* dan *Potential* memiliki korelasi positif. Namun, terdapat korelasi negatif yang kuat antara Umur dan *Potential*, yang secara logis membuktikan bahwa semakin tua seorang atlet, ruang (potensi) baginya untuk terus berkembang akan semakin kecil.